

Stable-Baselines3 + MuJoCo

強化学習入門

マイクロマウスプロジェクトで学ぶ実践的強化
学習



目次

1. 強化学習とは
2. 環境構築
3. Gymnasium環境の基本
4. MuJoCo環境の作成
5. Stable-Baselines3で学習
6. 学習結果の評価と可視化
7. 本プロジェクトで実践
8. 報酬設計の実践例

1. 強化学習とは

直感的な理解：試行錯誤で学ぶ

強化学習（Reinforcement Learning）は、**試行錯誤を通じて学ぶ**機械学習の手法

例：自転車の乗り方を覚える

1. 最初はバランスを崩して転ぶ（失敗 → 悪い結果）
2. 少しずつコツをつかむ（成功 → 良い結果）
3. 何度も試すうちに、上手に乗れるようになる

「やってみて、結果を見て、やり方を改善する」

他の機械学習との違い

手法	学習方法	例
教師あり学習	正解データから学ぶ	画像分類（猫/犬）
教師なし学習	データの構造を見つける	顧客のグループ分け
強化学習	試行錯誤で報酬を最大化	ゲームAI、ロボット制御

強化学習が適しているケース

-  正解を定義しにくいですが、良し悪しは判断できる
-  連続的な意思決定が必要
-  シミュレーションで大量の試行が可能

本プロジェクトの例

マウスをゴールに導く「正解の動き」を人間が定義するのは困難
→ 「ゴールに近づいたら良い」「壁にぶつかったら悪い」という報酬で学習

基本用語①：エージェントと環境

エージェント (Agent)

学習する主体 = ゲームの「プレイヤー」

→ 本プロジェクト：マイクロマウスロボット

環境 (Environment)

エージェントが行動する世界 = ゲームの「世界」

→ 本プロジェクト：MuJoCoで再現した迷路

基本用語②：状態と行動

状態・観測 (State / Observation)

環境の現在の情報 = 「今どういう状況か」

- 距離センサーの値 (前方の壁までの距離)
- 現在の速度、目標速度

行動 (Action)

エージェントが選択する操作 = コントローラー入力

- 左モーターの電圧 (-3V ~ +3V)
- 右モーターの電圧 (-3V ~ +3V)

基本用語③：報酬

報酬 (Reward)

行動の良し悪しを示す数値

状況	報酬
目標速度に近い	+1.0
目標速度から外れる	0.0 や負の値
壁にぶつかる	-10
ゴールに到達	+1000

エージェントは**報酬を最大化**するように学習する

報酬設計のポイント

✖ 悪い例

「ゴール到達時のみ +1」

→ ゴールに辿り着くまで何も学習できない（スパースすぎる）

✔ 良い例

「ゴールに近づくほど報酬が増える」

→ 少しずつ改善する方向がわかる

報酬設計は強化学習で最も重要な要素

基本用語④：ポリシーとエピソード

ポリシー (Policy)

状態から行動への対応規則 = ルールブック

ポリシー π : 状態 $s \rightarrow$ 行動 a

例：前方に壁が近い $\rightarrow$ 減速する

エピソード (Episode)

開始から終了までの一連の流れ = 1プレイ

- 開始：スタート位置に配置
- 終了：ゴール到達、衝突、時間切れ

強化学習のループ

① 観測 → ② 行動選択 → ③ 行動実行 → ④ 結果観測 → ⑤ 学習

↑

1. エージェントが環境の状態を**観測**
2. ポリシーに従って**行動を決定**
3. 環境に行動を**適用**
4. 新しい状態と**報酬を受け取る**
5. 報酬をもとにポリシーを**改善**

具体例：学習の流れ

ステップ1:

- 観測: 前方の壁まで0.1m、目標速度0.5m/s
- 行動: 加速（左右モーター2.0V）
- 結果: 速度0.45m/sに上昇 → **報酬 +0.9** ✓

ステップ2:

- 観測: 前方の壁まで0.05m（近い！）
- 行動: そのまま加速
- 結果: 壁に衝突！ → **報酬 -10** ✕

学習: 「壁が近いときに加速するのは良くない」

価値関数と割引率

長期的な報酬を考える

チェスの例：

- 今すぐ駒を取る (+1) → 次ターンでクイーンを取られる (-9) = 損
- 守る (0) → 数手後にチェックメイト (+100) = 得

割引率 γ (ガンマ)

$\gamma = 0.99$ の場合：

1ステップ後の報酬 $\times 0.99$

2ステップ後の報酬 $\times 0.99^2$

...

γ が 1 に近い → 長期的な報酬を重視

2. 環境構築

必要なパッケージ

```
# 仮想環境の作成（推奨）  
python -m venv .venv  
source .venv/bin/activate
```

```
# 必須パッケージ  
pip install mujoco           # 物理エンジン  
pip install gymnasium        # 環境インターフェース  
pip install stable-baselines3 # 強化学習アルゴリズム
```

```
# 可視化用  
pip install matplotlib opencv-python imageio
```


インストール確認

```
import mujoco
import gymnasium as gym
import stable_baselines3 as sb3

print(f"MuJoCo: {mujoco.__version__}")
print(f"Gymnasium: {gym.__version__}")
print(f"Stable-Baselines3: {sb3.__version__}")
```

3. Gymnasium環境の基本

Gymnasium とは

強化学習環境の**標準インターフェース**を提供するライブラリ
(旧 OpenAI Gym)

環境クラスの必須メソッド

メソッド	役割
<code>__init__()</code>	初期化、空間定義
<code>reset()</code>	環境をリセット
<code>step(action)</code>	1ステップ実行
<code>render()</code>	描画
<code>close()</code>	リソース解放

空間の定義

```
from gymnasium import spaces
import numpy as np

# 離散空間（選択肢から1つ選ぶ）
discrete = spaces.Discrete(4) # 0, 1, 2, 3

# 連続空間（範囲内の実数値）
box = spaces.Box(
    low=-1.0,
    high=1.0,
    shape=(2,), # 2次元
    dtype=np.float32
)
```

本プロジェクト：モーター電圧は**連続空間**

環境クラスのテンプレート

```
class MyEnv(gym.Env):
    def __init__(self, render_mode=None):
        # 行動空間：2次元連続値 [-1, 1]
        self.action_space = spaces.Box(
            low=-1.0, high=1.0, shape=(2,), dtype=np.float32
        )
        # 観測空間：4次元連続値
        self.observation_space = spaces.Box(
            low=-np.inf, high=np.inf, shape=(4,), dtype=np.float32
        )
```

reset() と step()

```
def reset(self, seed=None, options=None):
    """環境を初期状態にリセット"""
    observation = ... # 初期観測
    info = {}
    return observation, info

def step(self, action):
    """1ステップ実行"""
    observation = ... # 新しい観測
    reward = ... # 報酬
    terminated = ... # 終了フラグ（ゴール等）
    truncated = ... # 打ち切りフラグ（時間切れ等）
    info = {}
    return observation, reward, terminated, truncated, info
```

4. MuJoCo環境の作成

MuJoCo とは

Multi-Joint dynamics with Contact

高速で正確な物理シミュレーションエンジン

基本概念

概念	説明
モデル (MjModel)	シミュレーション世界の定義 (XML)
データ (MjData)	現在の状態
制御 (ctrl)	アクチュエータへの入力
センサー (sensordata)	センサー出力値

XMLモデルファイルの例

```
<mujoco model="simple_robot">
  <worldbody>
    <geom type="plane" size="1 1 0.1"/>  <!-- 地面 -->

    <body name="robot" pos="0 0 0.1">
      <joint type="free"/>
      <geom type="box" size="0.1 0.05 0.02"/>

      <!-- 車輪 -->
      <body name="left_wheel" pos="-0.05 0.06 0">
        <joint name="left_motor" type="hinge" axis="0 1 0"/>
        <geom type="cylinder" size="0.02 0.01"/>
      </body>
    </body>
  </worldbody>
</mujoco>
```

MuJoCo環境の実装

```
import mujoco

class MuJoCoEnv(gym.Env):
    def __init__(self, xml_file="model.xml"):
        # モデル読み込み
        self.model = mujoco.MjModel.from_xml_path(xml_file)
        self.data = mujoco.MjData(self.model)

    def step(self, action):
        # 制御入力を設定
        self.data.ctrl[:] = action * 3.0 # スケーリング

        # シミュレーション実行
        for _ in range(5):
            mujoco.mj_step(self.model, self.data)
```

5. Stable-Baselines3で学習

Stable-Baselines3 とは

PyTorchベースの高品質な強化学習アルゴリズム実装

対応アルゴリズム

アルゴリズム	行動空間	特徴
PPO	連続/離散	安定性が高く汎用的 ★推奨
SAC	連続	サンプル効率が高い
TD3	連続	高性能だがチューニング必要
A2C	連続/離散	シンプルで高速
DQN	離散のみ	離散行動の定番

PPO (Proximal Policy Optimization)

最も広く使われているアルゴリズム

特徴

- ポリシー勾配法的一种
- クリッピングで安定した学習
- Actor-Critic構造

メリット

- ハイパーパラメータに対してロバスト
- デフォルト値でも動くことが多い
- 連続・離散どちらにも対応

SAC (Soft Actor-Critic)

サンプル効率が低いオフポリシー手法

特徴

- 最大エントロピー強化学習
- 経験再生バッファを使用
- 探索と活用のバランスを自動調整

使いどころ

- 経験収集コストが高い場合（実機ロボットなど）
- 連続行動空間のみ

アルゴリズム選択ガイド

タスクの行動空間は？

- 離散（上下左右など）
 - DQN
- 連続（モーター電圧など）
 - 初心者 or 安定性重視 → PPO ★
 - サンプル効率重視 → SAC
 - 最高性能追求 → TD3

本プロジェクト：PPOを採用

→ シミュレーションで大量の経験を集められるため

基本的な学習コード

```
from stable_baselines3 import PP0
from stable_baselines3.common.callbacks import CheckpointCallback

# 環境作成
env = MyEnv(render_mode=None)

# モデル作成
model = PP0("MlpPolicy", env, verbose=1)

# 学習
model.learn(total_timesteps=1_000_000)

# 保存
model.save("models/my_model")
```


PPOのハイパーパラメータ

```
model = PPO(  
    "MlpPolicy",  
    env,  
    learning_rate=3e-4,      # 学習率  
    n_steps=2048,           # 更新前に収集するステップ数  
    batch_size=64,          # ミニバッチサイズ  
    n_epochs=10,             # エポック数  
    gamma=0.99,              # 割引率  
    clip_range=0.2,          # PPOクリップ範囲  
    verbose=1  
)
```

6. 学習結果の評価と可視化

学習済みモデルでテスト

```
from stable_baselines3 import PP0

# モデル読み込み
model = PP0.load("models/my_model")

# テスト環境（レンダリングあり）
env = MyEnv(render_mode="human")

obs, _ = env.reset()
for _ in range(1000):
    action, _ = model.predict(obs, deterministic=True)
    obs, reward, terminated, truncated, info = env.step(action)

    if terminated or truncated:
        obs, _ = env.reset()
```

動画の保存

```
import imageio

env = MyEnv(render_mode="rgb_array")
model = PPO.load("models/my_model")

frames = []
obs, _ = env.reset()

for _ in range(500):
    action, _ = model.predict(obs, deterministic=True)
    obs, reward, terminated, truncated, _ = env.step(action)
    frames.append(env.render())
    if terminated or truncated:
        break

imageio.mimsave("evaluation.mp4", frames, fps=30)
```

7. 本プロジェクトで実践

プロジェクト構造

```
micromouse_rl/  
├── phase1_open/      # 低レベル速度制御  
├── phase2_slalom/    # スラローム走行  
├── phase3_maze/      # 迷路ナビゲーション  
├── common/           # 共通ユーティリティ  
├── models/           # 訓練済みモデル  
└── assets/           # MuJoCo XMLファイル
```

階層型RL構造

Phase 3 Policy (高レベル)
↓ 目標速度 (線速度、角速度)
Phase 1 Controller (低レベル)
↓ モーター電圧
MuJoCo Physics Engine


- **Phase 1:** モーター制御を学習
- **Phase 3:** Phase 1を使って迷路ナビゲーション

Phase 1: 速度制御デモ

タスク: 目標速度を正確に追従

- 入力: センサー値、現在速度、目標速度
- 出力: 左右モーター電圧
- 報酬: 速度追従誤差の最小化

 デモ動画



Phase 2: スラローム走行デモ

タスク: L字カーブをスムーズに走行

- Phase 1を低レベル制御として使用
- 高レベルポリシーが目標速度を決定
- 階層型RLの実証

 デモ動画




Phase 3: 迷路ナビゲーション ンデモ

タスク: ランダム生成迷路でゴールに
到達

- 7×7のランダム迷路で汎化
- 中間目標を設定して段階的に誘導
- 壁との距離、進行方向も報酬に反映

 デモ動画




Phase 4: 高速走行学習デモ

タスク: 最速でゴールに到達

- Phase 3をベースに速度最大化を目標
- センサーパターンから最適速度を学習
- 直進では加速、ターン前では減速

 デモ動画



実行コマンド

```
# Phase 1: 低レベル制御の訓練
python phase1_open/train.py

# Phase 3: 迷路ナビゲーションの訓練
python phase3_maze/train.py

# Phase 4: 高速走行の訓練
python phase4_speed/train.py

# 評価
python phase4_speed/evaluate.py
```

8. 報酬設計の実践例

報酬設計の重要性

報酬関数は強化学習の成否を決める最重要要素

よくある失敗パターン

パターン	問題	結果
スパースすぎる	ゴール到達のみ報酬	学習が進まない
矛盾した報酬	速度報酬と安全報酬の競合	不安定な挙動
報酬ハッキング	意図しない抜け道	望まない行動を学習

Phase 1: 速度追従の報酬設計

目標: 指定された目標速度を正確に追従する

```
# 報酬関数
r_velocity = -|v_actual - v_target|      # 速度誤差ペナルティ
r_angular = -|ω_actual - ω_target|      # 角速度誤差ペナルティ
r_smooth = -|Δv| - |Δω|                 # 急な変化を抑制

reward = r_velocity + r_angular + r_smooth
```

設計理由

- **負の報酬（ペナルティ）方式:** 誤差を0に近づける学習が容易
- **スムーズネス報酬:** ガクガクした動きを防止

Phase 2: スラローム走行の報酬設計

目標: L字カーブをスムーズに通過する

```
r_progress = 20.0 * Δdist_to_goal # ゴール接近報酬
r_time = -0.01 # 時間ペナルティ
r_collision = -50.0 # 衝突ペナルティ
r_goal = 200.0 # ゴール到達報酬

reward = r_progress + r_time + r_collision + r_goal
```

設計理由

- **進行報酬:** 常に前進を促す（スパース報酬の回避）
- **時間ペナルティ:** 効率的なルート選択を促進

Phase 3: 迷路ナビゲーションの報酬設計

目標: ランダム迷路でゴールに到達する

```
r_goal = 400.0           # ゴール到達
r_intermediate = 100.0    # 中間目標到達
r_progress = 25.0 * Δdist # ゴール接近
r_speed = 0.2 * v         # 速度報酬
r_time = -0.03           # 時間ペナルティ
r_collision = -100.0      # 衝突ペナルティ

reward = r_goal + r_intermediate + r_progress + ...
```

設計理由

- 中間目標報酬: 2セル先のゴールへ段階的に誘導
- 低い速度報酬: 安全性を優先

Phase 4: 高速走行の報酬設計

目標: 安全かつ**最速**でゴールに到達する

```
r_goal = 500.0           # ゴール到達 (増額)
r_speed = 3.0 * v         # 速度報酬 (大幅強化)
r_time = -0.5            # 時間ペナルティ (強化)
r_angular = -0.1 * |ω|    # 蛇行抑制
r_straight = 0.3          # 直進ボーナス
r_smoothness = -0.3 * |Δv| - 0.3 * |Δω|

reward = r_goal + r_speed + r_time + r_angular + ...
```

Phase 3 → Phase 4: 報酬変更の比較

要素	Phase 3	Phase 4	変更理由
速度報酬	$0.2 \times v$	$3.0 \times v$	高速走行の強力な誘因
時間ペナルティ	-0.03	-0.5	早期到達への強い圧力
進行報酬	$25 \times \Delta d$	削除	速度報酬に統合
角速度ペナルティ	なし	$-0.1 \times \omega$	蛇行抑制
直進ボーナス	なし	+0.3	直線での加速促進

報酬調整の試行錯誤 (Phase 4)

実際の調整過程

バージョン	成功率	平均速度	問題点
v1	60%	0.96 m/s	蛇行が多い
v2	10%	0.99 m/s	角速度ペナルティが強すぎて旋回不能
v3	73%	0.93 m/s	バランス良好 ✓

学んだこと

- 報酬は慎重に調整: 小さな変更でも大きな影響
- 複数の指標を監視: 成功率だけでなく速度も確認
- 失敗から学ぶ: v2の失敗がv3の成功につながった

報酬設計のベストプラクティス

1. シェーピング報酬を活用

ゴールだけでなく、途中の良い行動にも報酬を与える

2. 報酬のスケールを意識

各報酬項目のバランスが重要（大きすぎると他を無視）

3. 段階的に複雑化

Phase 1 → 2 → 3 → 4 と段階的に難易度を上げる

4. 観察と修正

学習結果を観察し、問題があれば報酬を修正

報酬設計の課題と今後

現状の課題

本プロジェクトの報酬設計は、**アドホックな試行錯誤**の繰り返しに陥っている感が否めない

- 「うまくいかない → パラメータを変える → また試す」の泥沼
- 体系的なアプローチが欠如
- 最適な報酬構造に到達する保証がない

今後の展望

上位の研究者が用いるテクニックを調査・導入したい：

- **Reward Shaping** の理論的基盤（ポテンシャルベース等）
- **Inverse Reinforcement Learning**（エキスパートから報酬を学習）

まとめ

1. **Gymnasium** で環境インターフェースを実装
2. **MuJoCo** で物理シミュレーションを構築
3. **Stable-Baselines3** のPPOで学習
4. **報酬関数** の設計がタスク成功の鍵

次のステップ

- Phase 1から始めて段階的に挑戦
- 報酬関数を変えて実験
- ハイパーパラメータをチューニング

ありがとうございました

参考リンク

- [Stable-Baselines3 ドキュメント](#)
- [MuJoCo ドキュメント](#)
- [Gymnasium ドキュメント](#)